

**Universidad del Rosario**

**Matemáticas Aplicadas y Ciencias de la Computación**

**Análisis Estadístico de Datos**

**Análisis Multivariado de los Factores Asociados con la Esperanza de Vida en Distintos Países**

**Integrantes:**

**Samuel Andrés Fique Velasco**

**Alejandro Garzón Pulido**

**Nicolás Guzmán Acosta**

**Laura Triviño Parra**

**Profesora: Luz Adriana Pineda Barón**

**Bogotá, agosto de 2026**

**Semestre 2 - 2026**

## 1. Introducción

La esperanza de vida es un indicador ampliamente utilizado para describir las condiciones de salud y bienestar de una población, ya que refleja, de manera general, las condiciones sociales, económicas y sanitarias en las que vive una sociedad. Sin embargo, este indicador puede presentar diferencias importantes entre países debido a la interacción de múltiples factores, entre ellos las condiciones económicas, el acceso y la inversión en servicios de salud, la educación, la mortalidad y la cobertura de programas de inmunización. Por esta razón, estudiar la esperanza de vida requiere considerar simultáneamente diferentes dimensiones que pueden estar relacionadas con su comportamiento.

En este contexto, el presente proyecto utiliza una base de datos que contiene información de 179 países durante el período 2000–2015, con variables relacionadas con la esperanza de vida, factores socioeconómicos y diferentes indicadores de salud pública. Entre estas variables se encuentran el PIB, la composición del ingreso, los años de escolaridad, la mortalidad infantil y adulta, la cobertura de vacunación contra hepatitis B, poliomielitis y difteria, entre otras. La disponibilidad de estos factores permite estudiar estadísticamente cuáles presentan una mayor asociación con la esperanza de vida y analizar el fenómeno desde una perspectiva multivariable.

## 2. Planteamiento del problema

La literatura reciente confirma que un aumento en el PIB per cápita y en el gasto en salud favorece de manera sustancial la esperanza de vida, mientras que el crecimiento poblacional, la tasa de mortalidad y la mortalidad infantil la afectan negativamente (Kaluarachchi, 2026), y un estudio longitudinal sobre países en desarrollo encontró que factores como el PIB per cápita, la tasa de alfabetización, el estado nutricional y el régimen político contribuyeron conjuntamente al aumento de la esperanza de vida entre 1970 y 2004 (Lin et al., 2012); a pesar de esta evidencia, el peso relativo de estos factores no siempre resulta claro al compararse simultáneamente entre un número amplio de países, por lo que resulta pertinente analizar, usando estadística multivariada, la base de datos “*Life Expectancy (WHO) Fixed*” con el fin de identificar los factores socioeconómicos y de salud pública más asociados con la esperanza de vida en los países.

## 3. Pregunta de investigación

¿Qué factores socioeconómicos y de salud pública están más asociados con la esperanza de vida en los países?

## 4. Objetivos

**Objetivo general:** Analizar la asociación entre factores socioeconómicos y de salud pública con la esperanza de vida en los países, mediante técnicas de estadística multivariada aplicadas a la base de datos.

## Objetivos específicos

- a. Explorar la relación entre pares de variables (por ejemplo, esperanza de vida vs. escolaridad, o vs. gasto en salud) para identificar posibles patrones o diferencias entre grupos de países.
- b. Analizar la evolución de la esperanza de vida durante el período 2000–2015, considerando el contexto de acontecimientos relevantes de salud pública y socioeconómicos ocurridos durante este período en distintas regiones.
- c. Comparar las características socioeconómicas y de salud pública de los países desarrollados y en vía de desarrollo.

## 5. Revisión bibliográfica

**5.1** Abidin, N. Z., Abdullah, N., Nizam, R., & Shaari, M. S. M. (2025). Exploring the impacts of socioeconomic, political, and environmental determinants on life expectancy in ASEAN+3 nations. *Discover Sustainability*, 6(1), 1–18. <https://doi.org/10.1007/s43621-025-01472-7>

En el paper de Abidin et al. (2025) se analiza la relación entre factores socioeconómicos, políticos y ambientales y la esperanza de vida en países de ASEAN+3 durante 1995–2021, lo que lo hace relevante para nuestro proyecto. Los autores emplearon modelos de datos de panel, comparando mínimos cuadrados

ordinarios agrupados, efectos fijos y efectos aleatorios. Sus resultados mostraron una asociación positiva y significativa entre el ingreso laboral y la esperanza de vida, mientras que la percepción de corrupción y las emisiones de dióxido de carbono presentaron asociaciones negativas y significativas. Este estudio es un referente para nuestra investigación, ya que también analiza información de diferentes países y años y considera factores económicos y sociales. Sin embargo, nuestra base cuenta con un conjunto más amplio de variables, lo que nos permitirá identificar cuáles de los factores disponibles presentan una mayor asociación con la esperanza de vida.

## 5.2 Epidemiología del consumo de alcohol y de sus consecuencias en la salud

<https://socidrogalcohol.org/wp-content/Pdf/publicaciones/manuales-guias/Monografia-sobre-alcoholismo,%202012.pdf#page=44>

El consumo de alcohol es un factor que puede tener diferentes efectos sobre la salud dependiendo tanto de la cantidad ingerida como del patrón de consumo. Villalbí y Brugal (2012), en un capítulo publicado en la Monografía sobre el Alcoholismo de Socidrogalcohol, analizan distintas formas de medir este consumo y sus consecuencias desde una perspectiva poblacional.

Los autores realizan una revisión conceptual en la que comparan diferentes fuentes de información, como las ventas de bebidas, las encuestas a población

adulta y las encuestas escolares. Además, presentan el marco de Rehm, que relaciona la dosis y el patrón de consumo de alcohol con tres mecanismos intermedios: los efectos bioquímicos, la intoxicación y la dependencia. A partir de esto, describen la relación entre el consumo de alcohol y diversos problemas de salud. Por ejemplo, señalan que el riesgo de cirrosis hepática, pancreatitis y varios tipos de cáncer aumenta de manera proporcional al volumen consumido, mientras que otros efectos, como las arritmias cardíacas, se relacionan con episodios de consumo intensivo.

Estos resultados muestran que el consumo de alcohol puede estar relacionado con múltiples consecuencias para la salud, lo que hace que esta variable sea relevante para estudiar la esperanza de vida. En este sentido, el capítulo aporta elementos para interpretar alcohol\_consumption, especialmente al mostrar que sus efectos no dependen únicamente de la cantidad consumida, sino también del patrón de consumo y de los mecanismos asociados.

### **5.3 Factores determinantes de la esperanza de vida en Chile.**

En el artículo de Barahona-Urbina (2011), publicado por la Facultad de Medicina de la Universidad Nacional Mayor de San Marcos, el autor analiza los factores asociados a la esperanza de vida en Chile entre 1988 y 2008, donde se usa como variable dependiente la esperanza de vida en años y como variables independientes el PIB per cápita, el número de médicos, el número de enfermeras y el gasto

público en salud, lo que hace que sea una fuente importante dada la similitud con nuestras variables

Para abordar esto, el autor hizo un análisis descriptivo, usando la correlación de Pearson y diagramas de dispersión, junto con un modelo econométrico de regresión múltiple con series temporales, usando datos extra del Instituto Nacional de Estadísticas y el Banco Central de Chile. Los resultados mostraron correlaciones altas y positivas entre la esperanza de vida y las variables independientes. El modelo obtuvo un ajuste alto ( $R^2$  de 0,988) y se pudo observar que, cada 1000 dólares adicionales de PIB per cápita se asociaron con un incremento de 0,68 años en la esperanza de vida, y cada 10.000 médicos adicionales, con un aumento de 0,17 años.

Esto respalda el enfoque de nuestra pregunta de investigación sobre qué factores socioeconómicos y de salud pública están más asociados con este indicador en distintos países. Además, el autor señala como limitación no contar con variables adicionales relacionadas con la calidad de vida, como la educación o la alimentación, aspectos que nuestra base de datos sí incluye. A diferencia de este estudio, que analiza un único país durante 20 años, nosotros trabajaremos con varios países en un mismo periodo, lo que nos permitirá comparar estas relaciones entre distintos contextos y evaluar el papel de otras variables, como la escolaridad, la vacunación y la mortalidad infantil.

## 6. Marco metodológico

### Fuente de datos

Los datos utilizados en este proyecto provienen del dataset *"Life Expectancy (WHO) Fixed"* publicada en Kaggle. Es una versión corregida del dataset original *"Life Expectancy (WHO)"*, construida a partir de los repositorios públicos de la Organización Mundial de la Salud, el Banco Mundial y Our World in Data. A partir de esta base ya corregida, se hicieron modificaciones especificadas en la sección *"Preparación de la base de datos"* (Ver anexo A).

### Población o muestra

La población de estudio son 179 países, agrupados en 9 regiones geográficas (Medio Oriente, Unión Europea, Asia, Sudamérica, Centroamérica y el Caribe, resto de Europa, África, Oceanía y Norteamérica). No corresponde a una muestra probabilística de individuos, sino a un censo de países con información oficial por organismos internacionales.

### Número de observaciones

2,864 observaciones, correspondientes a 179 países registrados anualmente durante 16 años (2000–2015)

### Número de variables

La base de datos final cuenta con 23 variables (6 cualitativas y 17 cuantitativas)

- 3 categóricas originales (Country, Region, Status)

- 1 de tiempo (Year)
- 16 numéricas de salud y socioeconómicas
- 3 categóricas adicionales por terciles (Alto/Medio/Bajo)

### Contexto de recolección

Los datos originales fueron recolectados por la OMS y el Banco Mundial con el fin de monitorear indicadores de salud y desarrollo a nivel global. El periodo cubierto (2000–2015) antecede a eventos como la pandemia de COVID-19. El dataset fue modificado por el autor en Kaggle corrigiendo cifras y, para este proyecto, también modificado a un procesamiento adicional para corregir errores puntuales de captura de datos y modificar variables cuantitativas a variables categóricas útiles para el análisis sin perder información valiosa.

## 7. Preparación de la base de datos

Se verificó la totalidad de las columnas y no se encontraron valores NA, ya que la fuente incorpora un proceso de promedio de años cercanos por país, con respaldo por promedio regional.

Se comprobó que no existen filas duplicadas ni combinaciones repetidas de país-año; las 2.864 filas corresponden a observaciones únicas.

Las dos variables 'Economy\_status\_Developed' y 'Economy\_status\_Developing' se unificaron en una sola variable categórica Status (Developed/Developing), más

adecuada para tablas de contingencia y pruebas de asociación.

Para completar las seis variables cualitativas requeridas por el proyecto (ya se contaba con Country, Region y Status), se crearon tres variables categóricas adicionales 'GDP\_per\_capita\_cat', 'Schooling\_cat' y 'Adult\_mortality\_cat' a partir de sus respectivas variables numéricas, categorizadas en Bajo/Medio/Alto mediante terciles (cada categoría agrupa aproximadamente el 33 % de las observaciones). Las variables numéricas originales se conservaron intactas.

El dataset se ordenó por país y año. Adicionalmente, se identificaron y corrigieron dos errores de captura puntuales que la fuente no había resuelto: un patrón de "dígito perdido" en las variables de delgadez infantil (110 y 109 valores corregidos, reconstruidos a partir de la tendencia de cada país), y un registro atípico de Eritrea en 2015 (PIB per cápita y población con valores fuera de rango), corregido de forma manual y documentada. Otras variables revisadas (vacunación, alcohol, VIH, etc.) no presentaron errores sistemáticos.

La base final cuenta con 2.864 registros y 23 columnas, sin datos faltantes ni duplicados, lista para el análisis descriptivo.

## **8. Conclusiones preliminares**

8.1 El proyecto es viable, ya que la base de datos cuenta con la cantidad y estructura de información necesarias para

desarrollar el análisis planteado, con 2.864 observaciones de 179 países durante el período 2000-2015. Esto permite avanzar de manera progresiva desde el análisis descriptivo hasta la aplicación de técnicas de estadística multivariada, sin requerir fuentes de datos adicionales para cumplir con los objetivos del proyecto.

8.2 La base de datos es pertinente porque reúne variables económicas, sociales y de salud pública para un gran número de países, lo que permite abordar la pregunta de investigación desde una perspectiva multivariable. Adicionalmente, cumple con los requisitos al contar con 6 variables cualitativas y 17 cuantitativas, asegurando la información suficiente para aplicar las técnicas estadísticas previstas en las siguientes entregas.

8.3 La base de datos Life Expectancy (WHO) Fixed de Kaggle fue finalmente escogida y tratada para el análisis posterior a esta entrega en lugar del dataset original, puesto que corrige errores de captura relevantes presentes en la fuente original, como dígitos perdidos en variables como mortalidad adulta, PIB y población.

Con esto, la base de datos queda completa tras esta etapa, sin valores faltantes o registros duplicados, con las variables cualitativas y cuantitativas necesarias para cumplir con los requisitos propuestos en la rúbrica y para la aplicación de las distintas técnicas de análisis. La limpieza del dataset no se limitó solo a aceptarlo tal y como es originalmente en kaggle,

sino que también se contrastaron los errores con su versión original y se estudió en búsqueda de errores puntuales del nuevo dataset.

Si bien el dataset se encuentra completo y sin falta de datos, esta ausencia de datos faltantes se debe a que el autor aplicó una imputación previa de estos, con estrategias de promedio de años cercanos y promedio regional en las variables y los países donde faltaban datos

## 9. Referencias

Abidin, N. Z., Abdullah, N., Nizam, R., & Shaari, M. S. M. (2025). Exploring the impacts of socioeconomic, political, and environmental determinants on life expectancy in ASEAN+3 nations. *Discover Sustainability*, 6(1), 1–18. <https://doi.org/10.1007/s43621-025-01472-7>

Barahona-Urbina, P. (2011). Factores determinantes de la esperanza de vida en Chile. *Anales de la Facultad de Medicina*, 72(4). [http://www.scielo.org.pe/scielo.php?script=sci\\_arttext&pid=S1025-5583201100040006](http://www.scielo.org.pe/scielo.php?script=sci_arttext&pid=S1025-5583201100040006)

Kaluarachchi, D. (2026). Impact of socioeconomic factors on life expectancy: A global perspective across income levels. *Sustainable Development*. <https://doi.org/10.1002/sd.70702>

Lin, R.-T., Chen, Y.-M., Chien, L.-C., & Chan, C.-C. (2012). Political and social

determinants of life expectancy in less developed countries: A longitudinal study. *BMC Public Health*, 12, Artículo 85.

<https://doi.org/10.1186/1471-2458-12-85>

Villalbí, J. R., & Brugal, M. T. (2012). Epidemiología del consumo de alcohol y de sus consecuencias en la salud. En F. Pascual Pastor y J. Guardia Serecigni (Coords.), *Monografía sobre el alcoholismo* (pp. 43–74). Socidrogalcohol.

<https://socidrogalcohol.org/wp-content/Pdf/publicaciones/manuales-guias/Monografia-sobre-alcoholismo.%202012.pdf>

## 10. Declaración de uso IA

Durante la elaboración del proyecto se utilizaron herramientas de inteligencia artificial como apoyo para mejorar la redacción, revisar la estructura del documento, y orientar la organización de algunos apartados, como los códigos para poder corregir el dataset. La selección, procesamiento e interpretación de los datos, así como las decisiones metodológicas y el contenido final del proyecto, fueron revisados y comprendidos por los integrantes del grupo.

## 11. Anexos

Anexo A - Diccionario de variables

| Variable            | Descripción                                                                                                                                                               | Tipo de dato              | Escala de medición |
|---------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------|--------------------|
| Country             | Nombre del país (179 países).                                                                                                                                             | Texto (character)         | Nominal            |
| Region              | Región geográfica del país (9 regiones: Africa, Asia, European Union, Rest of Europe, Middle East, North America, South America, Central America and Caribbean, Oceania). | Texto (character)         | Nominal            |
| Status              | Clasificación económica del país: Developed o Developing. Unifica las dummies originales Economy_status_Developed / Economy_status_Developing.                            | Texto (character)         | Nominal            |
| Year                | Año de la observación (2000–2015).                                                                                                                                        | Numérico entero (integer) | Intervalo          |
| Infant_deaths       | Muertes de infantes (menores de 1 año) por cada 1000 habitantes.                                                                                                          | Numérico (double)         | Razón              |
| Under_five_deaths   | Muertes de menores de 5 años por cada 1000 habitantes.                                                                                                                    | Numérico (double)         | Razón              |
| Adult_mortality     | Probabilidad de morir entre los 15 y 60 años, por cada 1000 habitantes.                                                                                                   | Numérico (double)         | Razón              |
| Adult_mortality_cat | Tercil de Adult_mortality: Bajo / Medio / Alto.                                                                                                                           | Factor ordenado           | Ordinal            |
| Alcohol_consumption | Consumo de alcohol puro registrado, en litros per cápita, en personas de 15 años o más.                                                                                   | Numérico (double)         | Razón              |

|                             |                                                                                                                               |                      |         |
|-----------------------------|-------------------------------------------------------------------------------------------------------------------------------|----------------------|---------|
| Hepatitis_B                 | % de cobertura de inmunización contra Hepatitis B (HepB3) en niños de 1 año.                                                  | Numérico<br>(double) | Razón   |
| Measles                     | % de cobertura de inmunización contra sarampión (MCV1) en niños de 1 año.                                                     | Numérico<br>(double) | Razón   |
| BMI                         | Índice de masa corporal promedio de la población adulta (kg/m²).                                                              | Numérico<br>(double) | Razón   |
| Polio                       | % de cobertura de inmunización contra polio (Pol3) en niños de 1 año.                                                         | Numérico<br>(double) | Razón   |
| Diphtheria                  | % de cobertura de inmunización DTP3 (difteria, tétanos, tos ferina) en niños de 1 año.                                        | Numérico<br>(double) | Razón   |
| Incidents_HIV               | Incidencia de VIH por cada 1000 habitantes de 15 a 49 años.                                                                   | Numérico<br>(double) | Razón   |
| GDP_per_capita              | PIB per cápita, en dólares estadounidenses corrientes.                                                                        | Numérico<br>(double) | Razón   |
| GDP_per_capita_cat          | Tercil de GDP_per_capita: Bajo / Medio / Alto.                                                                                | Factor<br>ordenado   | Ordinal |
| Population_mln              | Población total del país, en millones.                                                                                        | Numérico<br>(double) | Razón   |
| Thinness_ten_nineteen_years | Prevalencia de delgadez (BMI < -2 desviaciones estándar de la mediana, referencia OMS) en adolescentes de 10 a 19 años, en %. | Numérico<br>(double) | Razón   |
| Thinness_five_nine_years    | Prevalencia de delgadez en niños de 5 a 9 años, en %.                                                                         | Numérico<br>(double) | Razón   |
| Schooling                   | Años promedio de escolaridad formal en personas de 25 años o más.                                                             | Numérico<br>(double) | Razón   |

|                 |                                                                                                |                   |         |
|-----------------|------------------------------------------------------------------------------------------------|-------------------|---------|
| Schooling_cat   | Tercil de Schooling: Bajo / Medio / Alto.                                                      | Factor ordenado   | Ordinal |
| Life_expectancy | Esperanza de vida promedio al nacer (ambos sexos), en años.<br>Variable objetivo del análisis. | Numérico (double) | Razón   |